工作流调度器 azkaban

为什么需要工作流调度系统

- 一个完整的数据分析系统通常都是由大量任务单元组成: shell 脚本程序, java 程序, mapreduce 程序、hive 脚本等
- 各任务单元之间存在时间先后及前后依赖关系
- 为了很好地组织起这样的复杂执行计划,需要一个工作流调度系统来调度执行;

例如,我们可能有这样一个需求,某个业务系统每天产生 20G 原始数据,我们每天都要对其进行处理,处理步骤如下所示:

- 1、通过 Hadoop 先将原始数据同步到 HDFS 上;
- 2、借助 MapReduce 计算框架对原始数据进行转换,生成的数据以分区表的形式存储到多 张 Hive 表中;
- 3、需要对 Hive 中多个表的数据进行 JOIN 处理,得到一个明细数据 Hive 大表;
- 4、将明细数据进行各种统计分析,得到结果报表信息;
- 5、需要将统计分析得到的结果数据同步到业务系统中、供业务调用使用。

工作流调度实现方式

简单的任务调度: 直接使用 linux 的 crontab 来定义;

复杂的任务调度: 开发调度平台或使用现成的开源调度系统, 比如 ooize、azkaban、airflow

等

常见工作流调度系统

市面上目前有许多工作流调度器

在 hadoop 领域,常见的工作流调度器有 Oozie, Azkaban, Cascading, Hamake 等

2Azkaban 介绍

概述

azkaban 官网:

https://azkaban.github.io/

Azkaban 是由 Linkedin 开源的一个批量工作流任务调度器。用于在一个工作流内以一个特定的顺序运行一组工作和流程。

Azkaban 定义了一种 KV 文件(properties)格式来建立任务之间的依赖关系,并提供一个易于使用的 web 用户界面维护和跟踪你的工作流。

它有如下功能特点:

- ◆ Web 用户界面
- ◆ 方便上传工作流
- ◇ 方便设置任务之间的关系
- ◇ 调度工作流
- ◇ 认证/授权(权限的工作)
- ◇ 能够杀死并重新启动工作流
- ◇ 模块化和可插拔的插件机制
- ◇ 项目工作区
- ◇ 工作流和任务的日志记录和审计

Azkaban 安装部署

2.3.2、azkaban 单服务模式安装与使用

所需软件

azkaban-solo-server

单服务模式安装

第一步:解压

azkaban 的 solo server 使用的是一个单节点的模式来进行启动服务的,只需要一个 azkaban-solo-server-0.1.0-SNAPSHOT.tar.gz 的安装包即可启动,所有的数据信息都是保存在 H2 这个 azkaban 默认的数据当中,

上传我们的压缩包, 然后修改配置文件启动即可

```
cd /export/softwares
tar -zxvf azkaban-solo-server-0.1.0-SNAPSHOT.tar.gz -C ../servers/
```

第二步:修改两个配置文件

修改时区配置文件

cd /export/servers/azkaban-solo-server-0.1.0-SNAPSHOT/conf vim azkaban.properties

default.timezone.id=Asia/Shanghai

```
# Azkaban Personalization Settings
azkaban.name=Slg1705 看你心情,随便,任意
azkaban.label=My Local Azkaban
azkaban.color=#FF3601
azkaban.default.servlet.path=/index
web.resource.dir=web/
default.timezone.id=Asia/Shanghai
# Azkaban UserManager class
user.manager.class=azkaban.user.XmlUserManager
user.manager.xml.file=conf/azkaban-users.xml
# Loader for projects
executor.global.properties=conf/global.properties
azkaban.project.dir=projects
database.type=h2
h2.path=./h2
h2.create.tables=true
# Velocity dev mode
velocity.dev.mode=false
# Azkaban Jetty server properties.
jetty.use.ssl=false
jetty.use.ssl=false
jetty.maxThreads=25
jetty.port=8081
# Azkaban Executor settings
executor.port=12321
# mail settings
mail.sender=
mail.host=
# User facing web server configurations used to construct
a reverse proxy between Azkaban web servers and users.
```

修改 commonprivate.properties 配置文件

```
cd /export/servers/azkaban-solo-server-0.1.0-SNAPSHOT/plugins/jobtypes vim commonprivate.properties
```

```
execute.as.user=false
memCheck.enabled=false
```

```
# set execute-as-user
execute.as.user=false
memCheck.enabled=false
~
~ 添加这一行,避免内存检查
```

第三步: 启动 solo-server

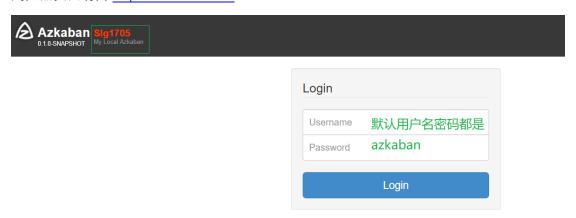
启动 azkaban-solo-server

cd /export/servers/azkaban-solo-server-0.1.0-SNAPSHOT bin/start-solo.sh

```
[root@node03 jobtypes]# cd /export/servers/azkaban-solo-server-0.1.0-SNAPSHOT
[root@node03 azkaban-solo-server-0.1.0-SNAPSHOT]# bin/start-solo.sh
[root@node03 azkaban-solo-server-0.1.0-SNAPSHOT]# jps
5504 AzkabanSingleServer
2599 Kafka
2538 QuorumPeerMain
3053 Application
2110 NodeManager
5534 Jps
1999 DataNode
```

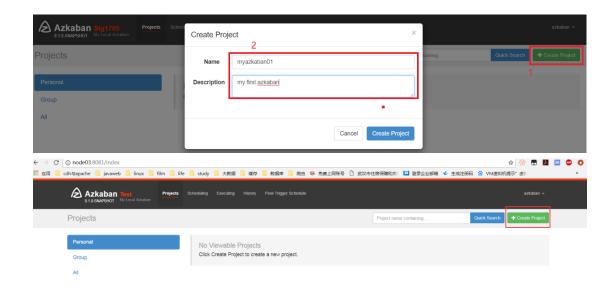
第四步:浏览器页面访问

浏览器页面访问 http://node03:8081/

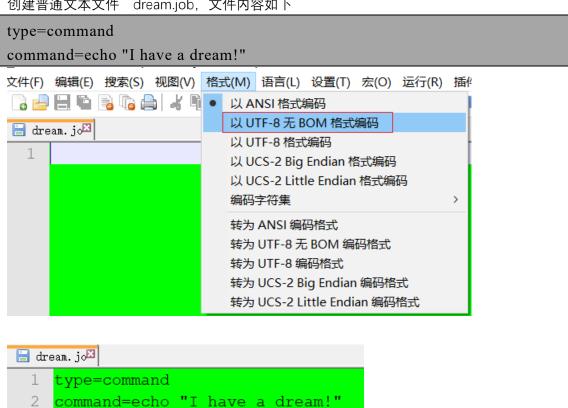


单服务模式使用

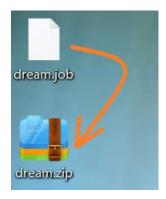
需求: 使用 azkaban 调度我们的 shell 脚本, 执行 linux 的 shell 命令



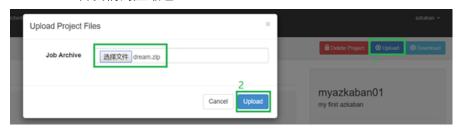
创建普通文本文件 dream.job, 文件内容如下

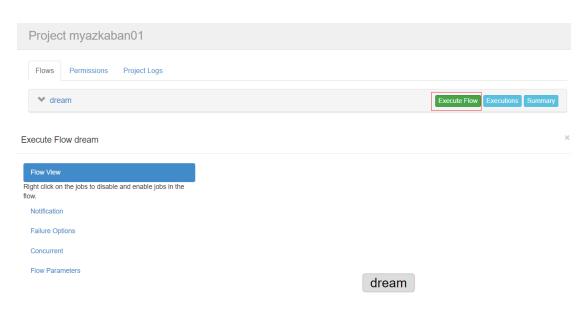


然后将这个文件打包为压缩文件,如下:

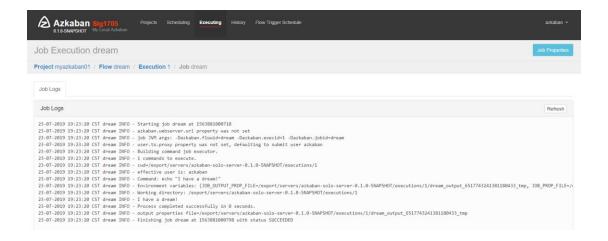


azkaban 上传我们的压缩包









2.3.3、azkaban 两个服务模式安装

1、确认所需软件:

Azkaban Web 服务安装包

azkaban-web-server-0.1.0-SNAPSHOT.tar.gz

Azkaban 执行服务安装包

azkaban-exec-server-0.1.0-SNAPSHOT.tar.gz

编译之后的 sql 脚本

create-all-sql-0.1.0-SNAPSHOT.sql

C程序文件脚本

execute-as-user.c 程序

2、数据库准备

进入 mysql 的客户端执行以下命令

mysql -uroot -p

执行以下命令:

CREATE DATABASE azkaban;

CREATE USER 'azkaban'@'%' IDENTIFIED BY 'azkaban';

GRANT all privileges ON azkaban.* to 'azkaban'@'%' identified by 'azkaban' WITH GRANT OPTION;

flush privileges;

use azkaban;

source /export/softwares/create-all-sql-0. 1. 0-SNAPSHOT. sql;

3、解压软件安装包

解压 azkaban-web-server

cd /export/softwares

tar -zxvf azkaban-web-server-0.1.0-SNAPSHOT.tar.gz -C \dots /servers/

cd /export/servers

mv azkaban-web-server-0.1.0-SNAPSHOT/ azkaban-web-server-3.51.0

解压 azkaban-exec-server

cd /export/softwares

tar -zxvf azkaban-exec-server-0.1.0-SNAPSHOT.tar.gz -C ../servers/

cd /export/servers

mv azkaban-exec-server-0.1.0-SNAPSHOT/ azkaban-exec-server-3.51.0

4、安装 SSL 安全认证 允许我们使用 https 的方式访问 azkaban 的 web 服务

密码 azkaban 一定要一个个的字母输入,或者粘贴也行

cd /export/servers/azkaban-web-server-3.51.0

keytool -keystore keystore -alias jetty -genkey -keyalg RSA

5、azkaban web server 安装

修改 azkaban-web-server 的配置文件

cd /export/servers/azkaban-web-server-3.51.0/conf vim azkaban.properties

```
# Azkaban Personalization Settings
azkaban.name=Azkaban
azkaban.label=My Azkaban
azkaban.color=#FF3601
azkaban.default.servlet.path=/index
web.resource.dir=web/
default.timezone.id=Asia/Shanghai
# Azkaban UserManager class
user.manager.class=azkaban.user.XmlUserManager
user.manager.xml.file=conf/azkaban-users.xml
# Loader for projects
executor.global.properties=conf/global.properties
azkaban.project.dir=projects
# Velocity dev mode
velocity.dev.mode=false
# Azkaban Jetty server properties.
jetty.use.ssl=true
jetty.maxThreads=25
jetty.port=8081
jetty.keystore=/export/servers/azkaban-web-server-3.51.0/keystore
jetty.password=azkaban
jetty.keypassword=azkaban
jetty.truststore=/export/servers/azkaban-web-server-3.51.0/keystore
jetty.trustpassword=azkaban
# Azkaban Executor settings
```

```
# mail settings
mail.sender=
mail.host=
# User facing web server configurations used to construct the user facing server
URLs. They are useful when there is a reverse proxy between Azkaban web
servers and users.
# enduser -> myazkabanhost:443 -> proxy -> localhost:8081
# when this parameters set then these parameters are used to generate email
links.
# if these parameters are not set then jetty.hostname, and jetty.port(if ssl
configured jetty.ssl.port) are used.
# azkaban.webserver.external hostname=myazkabanhost.com
# azkaban.webserver.external ssl port=443
# azkaban.webserver.external port=8081
job.failure.email=
job.success.email=
lockdown.create.projects=false
cache.directory=cache
# JMX stats
jetty.connector.stats=true
executor.connector.stats=true
# Azkaban mysql settings by default. Users should configure their own
username and password.
database.type=mysql
mysql.port=3306
mysql.host=node03
mysql.database=azkaban
mysql.user=azkaban
mysql.password=azkaban
mysql.numconnections=100
#Multiple Executor
azkaban.use.multiple.executors=true
#azkaban.executorselector.filters=StaticRemainingFlowSize,MinimumFreeMe
mory,CpuStatus
azkaban. executor selector. comparator. Number Of Assigned Flow Comparator = 1\\
azkaban.executorselector.comparator.Memory=1
azkaban.executorselector.comparator.LastDispatched=1
azkaban.executorselector.comparator.CpuUsage=1
```

6、azkaban executor server 安装

第一步:修改 azkaban-exex-server 配置文件

```
修改 azkaban-exec-server 的配置文件
cd /export/servers/azkaban-exec-server-3.51.0/conf
vim azkaban.properties
```

```
# Azkaban Personalization Settings
azkaban.name=Azkaban
azkaban.label=My Azkaban
azkaban.color=#FF3601
azkaban.default.servlet.path=/index
web.resource.dir=web/
default.timezone.id=Asia/Shanghai
# Azkaban UserManager class
user.manager.class=azkaban.user.XmlUserManager
user.manager.xml.file=conf/azkaban-users.xml
# Loader for projects
executor.global.properties=conf/global.properties
azkaban.project.dir=projects
# Velocity dev mode
velocity.dev.mode=false
# Azkaban Jetty server properties.
ietty.use.ssl=true
jetty.maxThreads=25
jetty.port=8081
jetty.keystore=/export/servers/azkaban-web-server-3.51.0/keystore
jetty.password=azkaban
jetty.keypassword=azkaban
jetty.truststore=/export/servers/azkaban-web-server-3.51.0/keystore
jetty.trustpassword=azkaban
```

```
# Where the Azkaban web server is located
azkaban.webserver.url=https://node03:8443
# mail settings
mail.sender=
mail.host=
# User facing web server configurations used to construct the user facing server
URLs. They are useful when there is a reverse proxy between Azkaban web
servers and users.
# enduser -> myazkabanhost:443 -> proxy -> localhost:8081
# when this parameters set then these parameters are used to generate email
links.
# if these parameters are not set then jetty.hostname, and jetty.port(if ssl
configured jetty.ssl.port) are used.
# azkaban.webserver.external hostname=myazkabanhost.com
# azkaban.webserver.external ssl port=443
# azkaban.webserver.external port=8081
job.failure.email=
job.success.email=
lockdown.create.projects=false
cache.directory=cache
# JMX stats
jetty.connector.stats=true
executor.connector.stats=true
# Azkaban plugin settings
azkaban.jobtype.plugin.dir=plugins/jobtypes
# Azkaban mysql settings by default. Users should configure their own
username and password.
database.type=mysql
mysql.port=3306
mysql.host=node03
mysql.database=azkaban
mysql.user=azkaban
mysql.password=azkaban
mysql.numconnections=100
# Azkaban Executor settings
executor.maxThreads=50
executor.flow.threads=30
```

第二步:添加插件

将我们编译后的 C 文件 execute-as-user.c

上传到这个目录来/export/servers/azkaban-exec-server-3.51.0/plugins/jobtypes或者直接将我们/export/softwares下面的文件拷贝过来也行

cp /export/softwares/execute-as-user.c /export/servers/azkaban-exec-server-3.51.0/plugins/jobtypes/

然后执行以下命令生成 execute-as-user

yum -y install gcc-c++
cd /export/servers/azkaban-exec-server-3.51.0/plugins/jobtypes
gcc execute-as-user.c -o execute-as-user
chown root execute-as-user
chmod 6050 execute-as-user

第三步:修改配置文件

3.51.0/plugins/jobtypes

修改配置文件

cd /export/servers/azkaban-exec-server-3.51.0/plugins/jobtypes vim commonprivate.properties

execute.as.user=false memCheck.enabled=false azkaban.native.lib=/export/servers/azkaban-exec-server-

7、启动服务

第一步: 启动 azkaban exec server

cd /export/servers/azkaban-exec-server-3.51.0

bin/start-exec.sh

第二步: 激活我们的 exec-server

node03 机器任意目录下执行以下命令(随机找个端口号进行激活)

curl -G "node03:\$(<./executor.port)/executor?action=activate" && echo

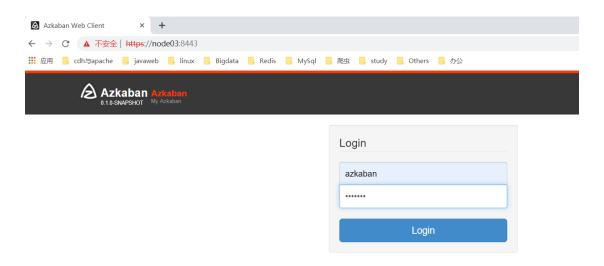
[root@node03 azkaban-exec-server-3.51.0]# curl -G "node03:\$(<./executor.port)/executor?action=activate" && echo {"status":"success"} [root@node03 azkaban-exec-server-3.51.0]#

第三步: 启动 azkaban-web-server

cd /export/servers/azkaban-web-server-3.51.0/bin/start-web.sh

访问地址:

https://node03:8443



修改 linux 的时区问题

由于先前做好了时钟同步,所以不用担心时区问题,不需要修改时区了

注: 先配置好服务器节点上的时区

- 1、先生成时区配置文件 Asia/Shanghai,用交互式命令 tzselect 即可
- 2、拷贝该时区文件,覆盖系统本地时区配置
- cp /usr/share/zoneinfo/Asia/Shanghai /etc/localtime

Azkaban 实战

Azkaba 内置的任务类型支持 command、java

Command 类型单一 job 示例

创建 job 描述文件

创建文本文件,更改名称为 mycommand.job 注意后缀.txt 一定不要带上,保存为格式为 UFT-8 without bom 内容如下

type=command

command=echo 'hello world'

将 job 资源文件打包成 zip 文件

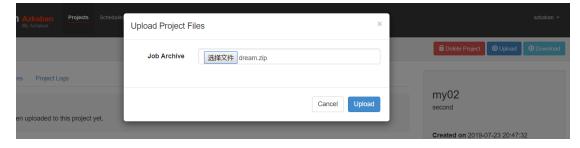


创建 project 并上传压缩包

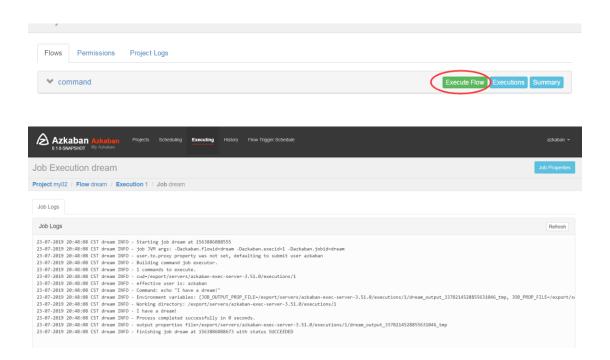
通过 azkaban 的 web 管理平台创建 project 并上传 job 压缩包首先创建 project

Azkaban Azkaban 0.1.0-SNAPSHOT My Azkaban Projects		Create Proje	ect		×	c			
Projects		Name	my02				taining	Quick Search	+ Create Project
Personal	П	Description	second						
Group					<i>(</i>)				
All				Cancel	Create Project				

上传 zip 包



启动执行 job



Command 类型多 job 工作流 flow

1、创建有依赖关系的多个 job 描述

第一个 job: foo.job

type=command
command=echo 'foo'

第二个 job: bar.job 依赖 foo.job

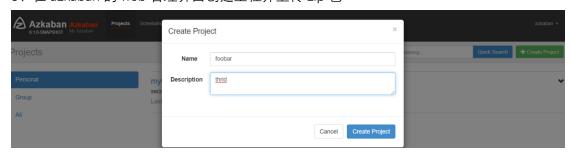
type=command

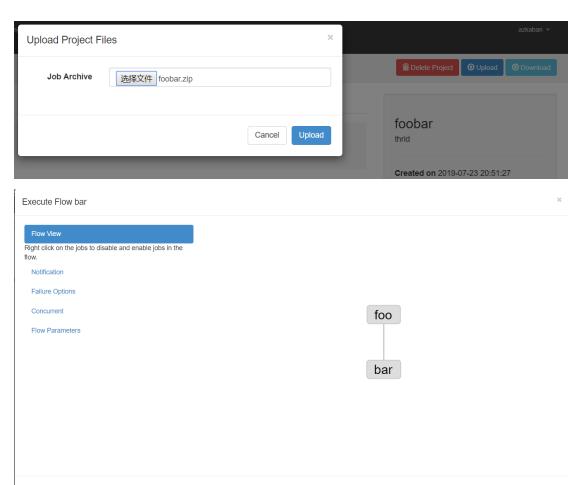
dependencies=foo command=echo 'bar'

2、将所有 job 资源文件打到一个 zip 包中



3、在 azkaban 的 web 管理界面创建工程并上传 zip 包

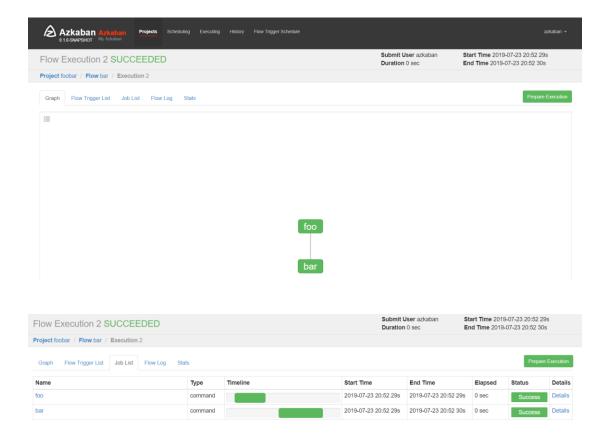




Cancel Execute

4、启动工作流 flow

Schedule

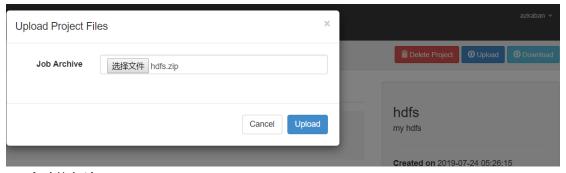


HDFS 操作任务(通过 azkaban 在 hdfs 上创建一个目录)

1、创建 job 描述文件 fs.job

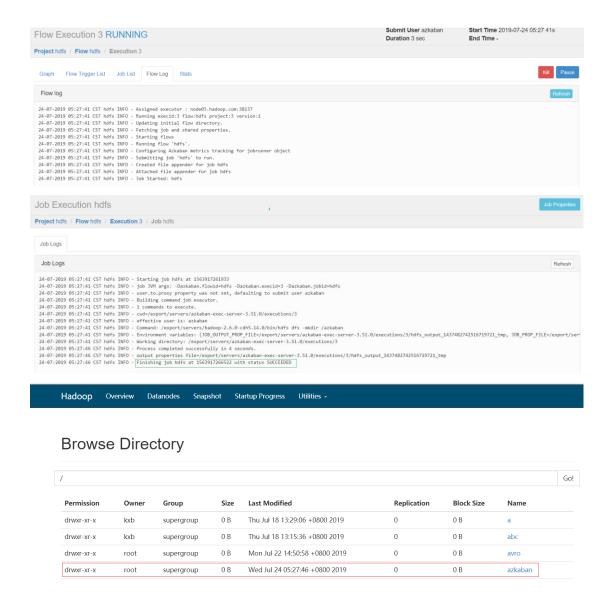
type=command
command=/export/servers/hadoop-2.6.0-cdh5.14.0/bin/hdfs dfs -mkdir
/azkaban

- 2、将 job 资源文件打包成 zip 文件
- 3、通过 azkaban 的 web 管理平台创建 project 并上传 job 压缩包



4、启动执行该 job





MAPREDUCE 任务

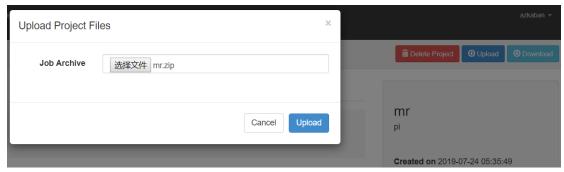
Mr 任务依然可以使用 command 的 job 类型来执行

1、创建 job 描述文件,及 mr 程序 jar 包(示例中直接使用 hadoop 自带的 example jar)

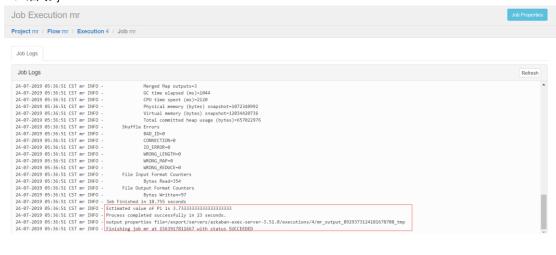
type=command

command=/export/servers/hadoop-2.6.0-cdh5.14.0/bin/hadoop jar hadoop-mapreduce-examples-2.6.0-cdh5.14.0.jar pi 3 5

2、将所有 job 资源文件打到一个 zip 包中



- 3、在 azkaban 的 web 管理界面创建工程并上传 zip 包
- 4、启动 job



HIVE 脚本任务

● 创建 job 描述文件和 hive 脚本

Hive 脚本: hive.sql

create database if not exists azhive;

use azhive;

create table if not exists aztest(id string,name string) row format delimited fields terminated by '\t';

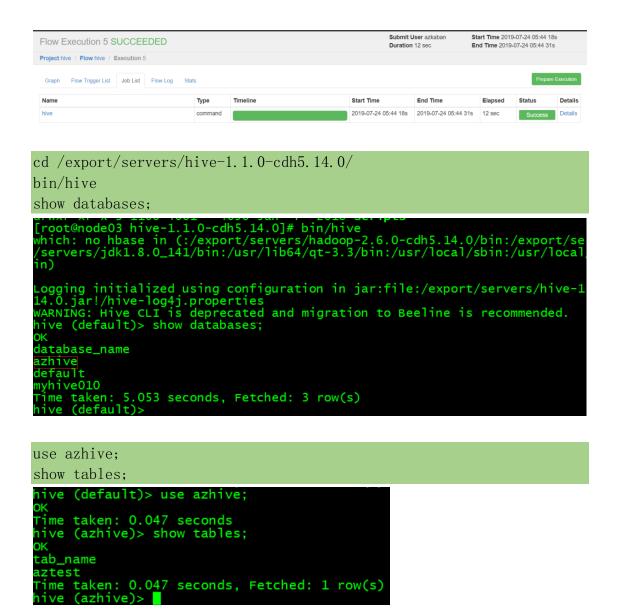
Job 描述文件: hive.job

type=command

command=/export/servers/hive-1.1.0-cdh5.14.0/bin/hive -f 'hive.sql'

将所有 job 资源文件打到一个 zip 包中

在 azkaban 的 web 管理界面创建工程并上传 zip 包 启动 job



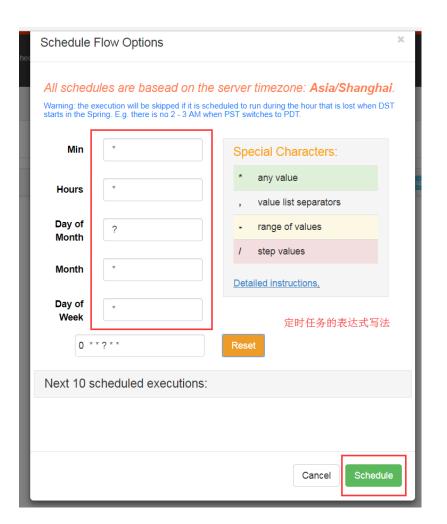
azkaban 的定时任务

使用 azkaban 的 scheduler 功能可以实现对我们的作业任务进行定时调度功能

Execute Flow dream









Linux下的crontab定时执行任务命令详解 - 回家的流浪者 - 博客园

2019年4月1日 - 1、如果两个文件都不存在,则只有root用户才能使用crontab命令。 2、如果cron.allow存在但cron.deny不存在,则只有列在cron.allow文件里的用户才能使用c...https://www.cnblogs.com/longjs... ▼ - 百度快照

crontab执行时间计算 - 在线工具

类型: Linux Java(Spring) crontab表达式: 执行时间 0 */12 * * * [user] [command] 请只输入红色部分。接下来7次的执行时间:...

tool.lu/crontab/ ▼ - 百度快照

crontab的使用方法介绍 - python小白的逆袭之路 - CSDN博客

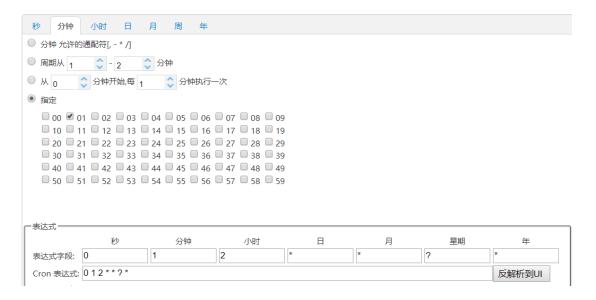
2018年6月9日 - 使用crontab你可以在指定的时间执行一个shell脚本或者一系列Linux命令。 例如系统管理员安排一个备份任务使其每天都运行…

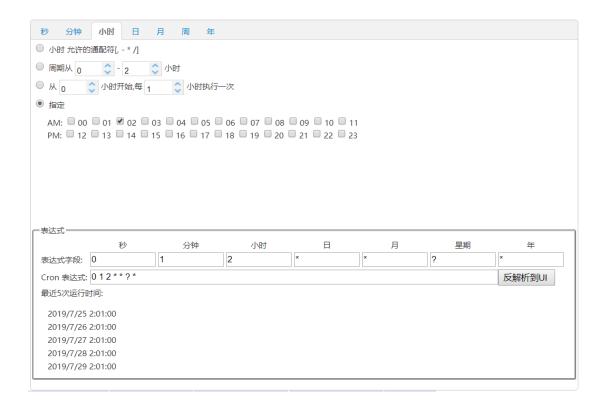
csDN - - <u>百度快照</u>

在线Cron表达式生成器

通过这个生成器,您可以在线生成任务调度比如Quartz的Cron表达式,对Quartz Cron 表达式的可视化双向解析和生成.
cron.qqe2.com/ * - 百度快照

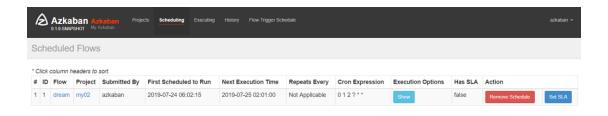
指定每一天的 2 点 01 分开始执行





此表达式从秒开始:





All schedules are basead on the server timezone: Asia/Shanghai.

Warning: the execution will be skipped if it is scheduled to run during the hour that is lost when DST starts in the Spring. E.g. there is no 2 - 3 AM when PST switches to PDT.

Min	1	Specia	al Characters:
Hours	2	*	any value
Tiours		,	value list separators
Day of Month	?	-	range of values
		1	step values
Month	*	0-23	allowed values
Day of Week	*	Detailed	l instructions.
Year			
real			
0 1	2?**	Reset	

Next 10 scheduled executions for this cron expression only:

- · 2019-07-25T02:01:00
- · 2019-07-26T02:01:00
- · 2019-07-27T02:01:00
- · 2019-07-28T02:01:00
- 2019-07-29T02:01:00